

MATHEMATICAL READER / 01

不確実性を 読む小さな本

一つの確率から、数式・曲線・画像へ



document-design · 図解で読む数学

CONTENTS

目次

二つの結果と一つの確率	3
確率を画像にする	5
色に頼らず曲線を読む	7
しきい値が残すもの	11
参考文献・奥付	13

本書について

本書は解説形式の組版サンプルである。数値と画像は、本文に示した関数から計算した。人物や実験、モデル性能の観測結果ではない。カラー図版、グレースケールの分析、白黒の付録を通して、同じ計算を異なる表現で読む。

第 1 章

二つの結果と一つの確率

ゼロか一を出力する情報源を考える。一が出る確率を p とすると、ゼロが出る確率は $1 - p$ となる。結果を二つ挙げれば何が起こりうるかは分かるが、それぞれの結果がどれだけ意外かは分からない。ほとんど常にゼロを出す情報源と、二つの結果を等確率で選ぶ情報源は異なる。

Shannonのエントロピーは、各結果に対応する情報量の平均によって確率分布を記述する。底を二とする対数を用いると、単位はビットとなる。二値情報源では、定義はそれぞれの結果に対応する二つの項にまとめられる。[1]

$$H(p) = -p \log_2 p - (1 - p) \log_2 (1 - p) \quad (1)$$

どちらの端点でも、一方の結果が確定している。 $0 \log_2 0 = 0$ という規約で式を連続的に拡張すると、 $H(0) = H(1) = 0$ となる。二つの結果が等確率のとき、 $p = 1/2$ を代入すれば $H(1/2) = 1$ ビットを得る。「ビット」という単位は情報量に属し、確率そのものに付くわけではない。

ゼロと一の名前を入れ替えると、 p は $1 - p$ に変わる。情報量の分布もエントロピーも変わらない。そのため曲線は $p = 1/2$ について対称となる。この対称性がないグラフは、軸や文字が整っていても、定義式と矛盾している。

この計算では、確率が既知であると仮定している。有限の標本から p を推定するなら、推定方法とその不確実性も論じる必要がある。ここに示した滑らかな曲線から、標本数や記号間の依存関係、特定の圧縮プログラムの動作を判断することはできない。

続く章では、同じ数学的対象を三つの読み方に分ける。画像は空間に並ぶ多くの確率を概観させる。曲線は入力の変化に対して指標がどう変わるかを示す。表は、選んだ値を明示した精度で残す。それぞれが異なる読み方に答える。

第 2 章

確率を画像にする

数式から画像の画素を作ることもしできる。単位正方形の位置 (x, y) ごとに、確率を次のように定義する。

$$p(x, y) = \frac{1 + \sin(4\pi x)\cos(2\pi y)}{2} \quad (2)$$

正弦と余弦は、それぞれ -1 から 1 の間の値を取る。その積も同じ区間に収まり、最後の変換で $[0, 1]$ に写される。これは構成した確率場であり、写真でも測定値でもない。



図1 $0 \leq x, y \leq 1$ における確率場。白は $p = 0$ 、最も濃い色は $p = 1$ を表す。 x は右へ、 y は上へ増加する。

出典：式(2)を両端を含む 1152×576 格子で計算。RGB を $(255, 255, 255)$ から $(0, 72, 112)$ へ補間した。

第3章

色に頼らず曲線を読む

量を見分ける方法は色だけではない。図2では、エントロピー H を実線と黒丸で、比較する V を破線と白抜き四角で示す。どちらも無彩色のインクで印刷しても、系列の区別が残る。

比較のため、正規化した分散を定義する。

$$V(p) = 4p(1 - p) \quad (3)$$




図2 ビット単位のエントロピー H と、無次元の正規化分散 V 。どちらも $p = 1/2$ で一となる。曲線の刻み幅は0.01、記号は表の確率に対応する。

表1 式(1)と式(3)から計算した値。表示時に小数第三位へ丸めた。

確率 p	エントロピー H [bit]	分散 V [1]
0.00	0.000	0.000
0.10	0.469	0.360
0.25	0.811	0.750
0.50	1.000	1.000
0.75	0.811	0.750
0.90	0.469	0.360
1.00	0.000	0.000

$p = 0.1$ では、 H は約0.469ビット、 V は0.360となる。両端と最大値は一致しても、中間の値は一致しない。数値の範囲が共通でも、二つの量を置き換えることはできない。比較するときには、値のそばに単位を残す必要がある。




図3 図1と同じ画像をグレースケールで表示したもの。青の色相は失われるが、空間的な濃淡のパターンは残る。

第4章

しきい値が残すもの

二色だけの画像では、中間の階調を捨てるか、別の形に符号化する必要がある。ここでは $p \geq 1/2$ の画素を黒、それ以外を白として再計算した。判定の境界は残るが、領域内の大きさの違いは失われる。




図4 確率場を二値化した画像。黒は $p \geq 1/2$ 、白は $p < 1/2$ を表す。同梱したPNGの元の画素は黒と白だけである。

黒い領域を見ても、確率が二分の一を少し超えたのか、一に近かったのかは分からない。この情報の欠落は表現の一部なので、キャプションにしきい値を示す。付録の

不確実性を読む小さな本

文字・罫線・図版も、黒いインクと白い紙、明示したラベルで同じ区別を保つ。

画像を使っても定義は必要である。数式が量を定め、キャプションが符号化を説明し、表が濃淡や曲線の読み取りに頼らず比較できる値を残す。

第 5 章

参考文献・奥付

-
- [1] C. E. Shannon. A Mathematical Theory of Communication.
<https://web.mit.edu/6.976/www/handout/shannon.pdf>
The Bell System Technical Journal, 27, 379-423, 623-656 (1948).
エントロピーの定義を参照。本書の確率場、正規化分散との比較、計算、図版は、解説のために独自に構成した。

doc-uiによる組版。MathMLの数式、SVGの曲線、同梱したPNG画像を同じ読むためのレイアウトに配置した。文字は選択でき、HTMLの閲覧と印刷にスクリプトや外部通信は必要ない。